

Sprawozdanie 1 z Statystyki i Modeli Liniowych

Wiktor Zoga

18 października 2025

1 Zadanie 4

1.1 Opis eksperymentu

W tym zadaniu w zależności od wartości parametrów:

- $\mu = 0, \theta = 1$
- $\mu = 0, \theta = 4$
- $\mu = 4, \theta = 1$
- $\mu = 4, \theta = 4$


esymowano wariancję próby wielkości $n = 50$ z rozkładu $N(\mu, \theta)$, przy pomocy trzech esymatorów:

- $\hat{\theta}_1 = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$
- $\hat{\theta}_2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \text{median}(X_1, \dots, X_n))^2$
- $\hat{\theta}_3 = \text{median}((X_1 - \bar{X})^2, \dots, (X_n - \bar{X})^2)$

Doświadczenie powtórzono 10,000 razy. Porównano esymatory przy pomocy wykresów pudełkowych oraz wyliczono wariancję, błąd średniokwadratowy oraz obciążenie każdego z esymatorów.

2 Wyniki


2.1 $\mu = 0, \theta = 1$



Rysunek 1: Boxplot estymatorów dla $\mu = 0, \theta = 1$.

Estymator	Średnia	Wariancja	Bias	MSE
est_1	1.0	0.04	0.0	0.04
est_2	1.01	0.04	0.01	0.04
est_3	0.46	0.02	-0.54	0.31


2.2 $\mu = 0, \theta = 4$



Rysunek 2: Boxplot estymatorów dla $\mu = 0, \theta = 4$.

Estymator	Średnia	Wariancja	Bias	MSE
est ₁	4.0	0.65	0.0	0.65
est ₂	4.05	0.67	0.05	0.68
est ₃	1.86	0.36	-2.14	4.95


2.3 $\mu = 4, \theta = 1$



Rysunek 3: Boxplot estymatorów dla $\mu = 4, \theta = 1$.

Estymator	Średnia	Wariancja	Bias	MSE
est ₁	1.0	0.04	0.0	0.04
est ₂	1.01	0.04	0.01	0.04
est ₃	0.46	0.02	-0.54	0.31

2.4 $\mu = 4, \theta = 4$



Rysunek 4: Boxplot estymatorów dla $\mu = 4, \theta = 4$.

Estymator	Średnia	Wariancja	Bias	MSE
est ₁	4.0	0.65	0.0	0.65
est ₂	4.04	0.67	0.04	0.67
est ₃	1.86	0.35	-2.14	4.95

3 Dyskusja Wyników

W tym zadaniu celem była estymacja parametru θ , który w notacji rozkładu $\mathcal{N}(\mu, \theta)$ odpowiada **wariancji**.

Analiza Estymatora $\hat{\theta}_1 = S^2$

Jest to klasyczny, **nieobciążony estymator wariancji** z próby.

- **Obciążenie:** Zgodnie z rachunkami, które przeprowadziliśmy na wykładzie $E[S^2] = E[\hat{\theta}_1] = \sigma^2 = \theta$.
- **MSE:** Ponieważ estymator jest nieobciążony, jego MSE jest równe jego wariancji: $\text{MSE}(\hat{\theta}_1) = \text{Var}(\hat{\theta}_1)$.

Dokładnie to:

$$E[S^2] = \sigma^2, \quad \text{Var}(S^2) = \frac{2\sigma^4}{n-1}$$

- Gdy $\theta = 1$ (wariancja populacji), $\text{MSE}(\hat{\theta}_1) = \frac{2 \cdot 1^2}{49} \approx 0.04$.
- Gdy $\theta = 4$ (wariancja populacji), $\text{MSE}(\hat{\theta}_1) = \frac{2 \cdot 4^2}{49} = \frac{32}{49} \approx 0.65$.

Wyniki eksperymentu zgadzają się z teoretycznymi obliczeniami.

Analiza Estymatora $\hat{\theta}_2$

Estymator ten jest analogiczną konstrukcją do S^2 , jednak zamiast optymalnego estymatora średniej $\bar{X}$, używa on estymatora odpornego – **mediany** ($\hat{m} = \text{median}(X)$).

- W rozkładzie normalnym $\hat{m}$ jest również nieobciążonym estymatorem μ , jednak jest on **mniej efektywny** (ma większą wariancję) niż $\bar{X}$.
- Ponieważ do obliczenia $\hat{\theta}_2$ używamy "mniej dokładnego oszacowania środka rozkładu, intuicyjnie spodziewamy się, że $\hat{\theta}_2$ będzie **nieco gorszym** estymatorem wariancji θ niż $\hat{\theta}_1$.
- Wyniki symulacji sugerują, że jest to estymator poprawny i bardzo zbliżony do $\hat{\theta}_1$, jednak różnica w biasie i MSE jest zauważalna.

Analiza Estymatora $\hat{\theta}_3$

Estymator $\hat{\theta}_3 = \text{median}((X_i - \bar{X})^2)$ jest przykładem estymatora **obciążonego**.

Analiza asymptotyczna

Aby formalnie wykazać obciążenie, zbadajmy granicę, do której zbiega estymator. Wraz ze wzrostem $n \rightarrow \infty$, średnia z próby $\bar{X}$ zbiega do μ . Zatem $\hat{\theta}_3$ zbiega (według prawdopodobieństwa) do $m = \text{median}((X_i - \mu)^2)$.

Musimy wyznaczyć wartość tej mediany m .

- Niech $X_i \sim \mathcal{N}(\mu, \theta)$.

- Standaryzujemy zmienną: $Z = (X_i - \mu)/\sqrt{\theta}$, gdzie $Z \sim \mathcal{N}(0, 1)$.
- Kwadrat tej zmiennej, Z^2 , ma rozkład χ_1^2 (Chi-kwadrat z 1 stopniem swobody).

Wartość m , do której zbiega estymator, to:

$$m = \text{median}((X_i - \mu)^2) = \text{median}(\theta \cdot Z^2) = \theta \cdot \text{median}(\chi_1^2)$$

Mediana rozkładu χ_1^2 to wartość t , dla której $P(Z^2 \leq t) = 2\Phi(\sqrt{t}) - 1 = 0.5$. Jak wynika z obliczeń, $t = (\Phi^{-1}(0.75))^2 \approx (0.6745)^2 \approx \mathbf{0.4549}$.

Wnioski z symulacji

Oznacza to, że estymator $\hat{\theta}_3$ nie zbiega do θ , lecz do $\approx 0.4549 \cdot \theta$. Fakt ten w pełni wyjaśnia wyniki obserwowane w symulacji:

- Estymator wykazuje **znaczące obciążenie**, systematycznie zaniżając prawdziwą wariancję θ o około 55%.
- Obserwacja z eksperymentu dla $\theta = 4$ (gdzie wynik był ≈ 1.86) jest bardzo bliska wartości teoretycznej, $4 \cdot 0.4549 \approx 1.82$.
- To duże obciążenie jest głównym składnikiem **wysokiego błędu średniokwadratowego (MSE)**, zgodnie ze wzorem $\text{MSE} = \text{Var} + \text{Bias}^2$.