

Sprawozdanie: Laboratorium 4

Regresja liniowa prosta

Wiktor Zoga

18 stycznia 2026

1 Zadanie 1

1.1 Analiza wstępna i model (Podpunkt a)

Na podstawie wygenerowanego wykresu punktowego (Rysunek 1) stwierdzono, że zależność między liczbą kopiarek a czasem obsługi ma liniowy charakter. Wraz ze wzrostem liczby maszyn, czas obsługi rośnie proporcjonalnie.

Wyznaczone równanie regresji liniowej prostej:

$$\hat{Y} = \text{Intercept} + \text{Slope} \cdot X \quad (1)$$

(Szczegółowe wartości liczbowe parametrów znajdują się w tabeli poniżej).

1.2 Estymacja parametrów (Podpunkt b)

Poniższa tabela przedstawia oszacowane wartości współczynników (Slope, Intercept) oraz ich błędy standardowe. Porównano wyniki uzyskane z ręcznych wzorów teoretycznych oraz z biblioteki Python (różnice są pomijalne, wynikają z zaokrągleń maszynowych).

Tabela 1: Porównanie parametrów modelu

	Man Coef	Lib Coef	Man SE	Lib SE	Man P-val	Lib P-val
Intercept	-0.5802	-0.5802	2.8039	2.8039	0.8371	0.8371
Slope	15.0352	15.0352	0.4831	0.4831	0.0000	0.0000

1.3 Testy istotności i interpretacja P-value (Podpunkt c)

Przeprowadzono test t-Studenta dla współczynnika kierunkowego (Slope, β_1).

Definicja matematyczna: Testujemy hipotezę zerową $H_0 : \beta_1 = 0$ (brak zależności) przeciwko $H_1 : \beta_1 \neq 0$. Statystyka testowa t sprawdza, jak wiele błędów standardowych dzieli nasz wynik od zera.

Wyniki: Na podstawie tabeli powyżej, p-wartość (P-val) dla Slope jest bliska zeru ($p < 0.05$).

Interpretacja (dla niematematyka): Jeśli założymy, że liczba kopiarek NIE ma wpływu na czas (hipoteza zerowa jest prawdziwa), to prawdopodobieństwo zaobserwowania takich danych jak nasze wynosi niemal 0%. Oznacza to, że dane dużym prawdopodobieństwem świadczą, że hipoteza zerowa jest fałszywa.

Decyzja: Odrzucamy hipotezę zerową. Współczynnik kierunkowy jest istotny statystycznie.

1.4 Analiza predykcyjna (Podpunkty d, e)

Dokonano estymacji dla zadanych wartości $k \in \{1, 5, 8, 11, 25, 100\}$.

1. Przedział ufności dla wartości oczekiwanej (CI):


Tabela 2: Porównanie CI dla wartości oczekiwanej				
	Man CI Low	Lib CI Low	Man CI High	Lib CI High
k				
1	9.6361	9.6361	19.2740	19.2740
5	71.9142	71.9142	77.2779	77.2779
8	115.8157	115.8157	123.5879	123.5879
11	158.4754	158.4754	171.1397	171.1397
25	355.7401	355.7401	394.8620	394.8620
100	1410.4614	1410.4614	1595.4279	1595.4279

2. Przedział predykcyjny dla nowej obserwacji (PI):

Tabela 3: Porównanie PI dla nowej obserwacji				
	Man PI Low	Lib PI Low	Man PI High	Lib PI High
k				
1	-4.1554	-4.1554	33.0656	33.0656
5	56.4213	56.4213	92.7708	92.7708
8	101.3108	101.3108	138.0929	138.0929
11	145.7491	145.7491	183.8660	183.8660
25	348.7349	348.7349	401.8672	401.8672
100	1408.7307	1408.7307	1597.1586	1597.1586

Wnioski: W obu przypadkach przedziały rozszerzają się, im dalej wartość X znajduje się od średniej $\bar{X}$. Wynika to ze wzrostu niepewności estymacji linii regresji na krańcach zbioru danych.

1.5 Wizualizacja i porównanie przedziałów (Podpunkt f)



Rysunek 1: Model regresji z naniesionymi 95% pasmami ufności (niebieskie) i predykcji (zielone).

Dlaczego PI (zielony) jest szerszy niż CI (niebieski)?

- **Matematycznie:** Wariancja predykcji zawiera dodatkowy składnik „1” pod pierwiastkiem: $s_{pred}^2 = s^2(1 + \dots)$.
- **Intuicyjnie:** CI (Przedział Ufności) mówi nam, gdzie leży *średnia* (np. "Jaki jest średni czas serwisu dla 5 kopiarek?"). PI (Przedział Predykcji) mówi o *konkretnym przypadku* (np. "Ile czasu zajmie serwis u Pana Kowalskiego jutro?").

PI musi uwzględniać nie tylko błąd naszego modelu, ale też naturalną losowość (szum) pojedynczego zdarzenia, dlatego zawsze jest szerszy.

2 Zadanie 2

2.1 Model regresji GPA od IQ (Podpunkt a)

Zbadano wpływ wyniku testu IQ na średnią ocen (GPA).

Współczynnik determinacji R^2 : Poniższa tabela porównuje wartość R^2 obliczoną ze wzoru teoretycznego oraz funkcją biblioteczną.

Tabela 4: Współczynnik determinacji (Manual vs Python)

	Man	Lib	Diff
R-squared	0.4016	0.4016	0.0000

Interpretacja R^2 (dla niematematyka): Współczynnik R^2 mówi nam, jaki procent zmienności ocen został rozwiązany przez nasz model. Wartość $R^2 \approx 0.4$ (przykładowo) oznaczałaby, że inteligencja (IQ) wyjaśnia 40% różnic w ocenach między uczniami. Pozostałe 60% zależy od innych czynników (np. pracowitość, stres, losowość), których model nie uwzględnia.

2.2 Test F istotności regresji (Podpunkt b)

Test F (ANOVA) służy do sprawdzenia, czy model jako całość ma sens.

- $H_0 : \beta_1 = 0$ (Model nie wyjaśnia niczego lepiej niż zwykła średnia).
- $H_1 : \beta_1 \neq 0$ (Model wnosi istotną informację).

Wyniki testu (Manual vs Python):

Tabela 5: Wyniki testu F (Manual vs Python)

	Man	Lib	Diff
Statystyka F	51.0085	51.0085	0.0000
P-wartość	4.74e-10	4.74e-10	0.0000

Decyzja: Niska p-wartość ($p < 0.05$) oznacza, że odrzucamy H_0 . Zatem wariancja wyjaśniona przez model jest istotnie większa od szumu.


Interpretacja (dla niematematyka): Podobnie jak wcześniej, niska p-wartość wskazuje, że jest mało prawdopodobne, aby zaobserwowane dane pojawiły się przypadkowo, gdyby IQ nie miało wpływu na GPA. Oznacza to, że IQ jest istotnym predyktorem GPA.

2.3 Predykcja i analiza obserwacji (Podpunkty c, d)

Wyznaczono przewidywane GPA oraz 90% przedziały predykcyjne dla uczniów o IQ: 75, 100, 140.

Tabela 6: 90% Przedziały predykcyjne (Manual vs Lib)

	GPA Pred	Man Low	Lib Low	Man High	Lib High
IQ					
75	4.0196	1.1659	1.1659	6.8732	6.8732
100	6.5451	3.7975	3.7975	9.2927	9.2927
140	10.5860	7.7503	7.7503	13.4216	13.4216



Rysunek 2: Zależność GPA od IQ z naniesionym 90% pasmem predykcji. Czerwone krzyżyki oznaczają obserwacje wykraczające poza ten przedział.

2.4 Porównanie z testem PH (Podpunkt e)

W ostatnim kroku zbudowano drugi model, gdzie zmienną objaśniającą jest wynik testu PH.

Tabela 7: Porównanie jakości modeli (IQ vs PH)

	R-squared	Intercept	Slope
Predyktor			
IQ	0.4016	-3.5571	0.1010
PH	0.2936	2.2259	0.0917

Wniosek końcowy: Porównując współczynniki R^2 obu modeli, wskazujemy ten, który lepiej "tłumaczy" rzeczywistość. Zmienna z wyższym R^2 jest silniejszym predyktorem.

3 Zadanie 3: Symulacje Monte Carlo

3.1 Specyfikacja eksperymentu

Symulację przeprowadzono dla $N = 1000$ powtórzeń przy liczebności próby $n = 200$. Wektor X wygenerowano z rozkładu $X \sim N(0, \frac{1}{500}I)$. Model generujący: $Y = 5 + \beta_1 X + \varepsilon$. Badano 6 scenariuszy rozkładu błędów ε :

- **Błąd I Rodzaju** ($\beta_1 = 0$): (a) $N(0, 1)$, (b) $Exp(1)$, (c) $L(0, 1)$.
- **Moc Testu** ($\beta_1 = 2$): (d) $N(0, 1)$, (e) $Exp(1)$, (f) $L(0, 1)$.

3.2 Wyniki symulacji

Tabela przedstawia empiryczne prawdopodobieństwo odrzucenia H_0 w zestawieniu z teorią.

Tabela 8: Wyniki symulacji (1000 powtórzeń)

ID	Beta1	Dist	Emp	Theo	Diff
(a)	0	Normal	0.0440	0.0500	-0.0060
(b)	0	Exp(1)	0.0470	0.0500	-0.0030
(c)	0	Logistic	0.0400	0.0500	-0.0100
(d)	2	Normal	0.2460	0.2501	-0.0041
(e)	2	Exp(1)	0.2530	0.2501	0.0029
(f)	2	Logistic	0.1050	0.1091	-0.0041


3.3 Analiza zgodności wyników

1. Błąd I rodzaju (Scenariusze a, b, c): Empiryczne częstości odrzuceń oscylują wokół $\alpha = 0.05$, co potwierdza ogólną odporność testu.

- **Uwaga o rozbieżności:** Dla rozkładu logistycznego wynik empiryczny jest nieco niższy od teoretycznego. Wynika to z "grubych ogonów" tego rozkładu i wolniejszego tempa zbieżności statystyk do rozkładu t-Studenta. Przy takiej zbieżności, liczba powtórzeń symulacji $N = 1000$ może być niewystarczająca, by idealnie trafić w punkt 0.05 (błąd próbkowania).

2. Moc testu (Scenariusze d, e, f): Obserwujemy niemal idealną zgodność symulacji z teorią.

- Dla rozkładu Normalnego i Wykładniczego ($\sigma^2 = 1$) moc wynosi ≈ 1.0 .
- Dla rozkładu Logistycznego moc spada. Jest to skutek dużej wariancji szumu. Teoria idealnie przewiduje ten spadek, gdy do wzorów podstawimy rzeczywistą wariancję.



Rysunek 3: Wizualizacja wyników: Zauważalny spadek mocy dla przypadku (f) oraz wysoka zgodność teorii z praktyką.

4 Zadanie 4

4.1 Model Liniowy (Podpunkty a, b)

W pierwszej kolejności dopasowano klasyczny model regresji liniowej, traktując czas jako zmienną objaśniającą (X), a stężenie roztworu jako zmienną odpowiedzi (Y).

$$Y = \beta_0 + \beta_1 \cdot \text{Czas} + \varepsilon \quad (2)$$

1. Wyniki estymacji i test istotności: Poniższa tabela prezentuje parametry modelu wygenerowane automatycznie przez skrypt Python.

Tabela 9: Parametry modelu liniowego

	Coef	SE	t	P-val
Intercept	2.5753	0.2487	10.3538	1.20e-07
Time	-0.3240	0.0433	-7.4829	4.61e-06

Statystyki dopasowania:

Tabela 10: Statystyki dopasowania modelu liniowego

	R-squared	Corr	F-stat	P-val (F)
Model Liniowy	0.8116	0.9009	55.9938	4.61e-06

Interpretacja parametrów:

- **Slope (Time):** Wynosi ok. -0.3240 . Ujemny znak potwierdza, że wraz z upływem czasu stężenie roztworu maleje.
- **Intercept:** Wynosi ok. 2.5753 . Jest to teoretyczne stężenie w chwili $t = 0$.


Test hipotezy: Testujemy hipotezę o niezależności stężenia od czasu:

- $H_0 : \beta_1 = 0$ (Czas nie wpływa na stężenie).
- $H_1 : \beta_1 \neq 0$ (Istnieje zależność).

Wniosek: P-wartość dla parametru czasu wynosi 4.61×10^{-6} (jest znacznie mniejsza od poziomu istotności $\alpha = 0.05$). **Decyzja:** Odrzucamy hipotezę zerową. Istnieje silna, istotna statystycznie zależność między czasem a stężeniem.

2. Ocena dopasowania (Dlaczego model liniowy jest błędny?) Mimo że parametry są istotne, model liniowy jest **niepoprawny** z dwóch powodów:

1. **Fizyczny:** Model liniowy zakłada stały spadek stężenia. W dłuższym czasie przewidywałby ujemne stężenie (dla $t > 8$ godzin), co jest fizycznie niemożliwe.
2. **Statystyczny:** Wykres reszt wykazuje wyraźny wzorec w kształcie litery "U". Model przeszacowuje wartości na krańcach i niedoszacowuje w środku. Sureguje to, że zjawisko jest nieliniowe.



Rysunek 4: Model liniowy (po lewej) oraz wykres reszt (po prawej), który obnaża nieliniowość danych.

4.2 Transformacja Boxa-Coxa (Podpunkt c)

Aby znaleźć optymalną transformację zmiennej zależnej Y , zastosowano metodę największej wiarygodności dla rodziny transformacji potęgowych Boxa-Coxa.

1. Weryfikacja obliczeń (Manual vs Python): Aby potwierdzić poprawność wyniku, wyznaczono optymalne λ dwoma metodami:

- **Manualnie:** Przeszukując siatkę 1000 punktów w przedziale $[-2, 2]$ i obliczając dla każdego punktu wartość funkcji log-wiarygodności wg wzoru:

$$LL(\lambda) = -\frac{n}{2} \ln(\sigma_\lambda^2) + (\lambda - 1) \sum \ln(Y_i)$$

- **Bibliotecznie:** Używając optymalizatora `scipy.stats.boxcox`.

Tabela 11: Porównanie optymalnego parametru Lambda

Znalezione Lambda	
Metoda	
Manualna	0.0220
Biblioteczna	0.0205

Wyniki są zbieżne. Obie metody wskazują, że optimum leży bardzo blisko zera. Zgodnie z definicją Boxa-Coxa, $\lambda = 0$ oznacza transformację logarytmiczną ($Y' = \ln Y$).

4.3 Model Logarytmiczny (Podpunkty d, e)

Na podstawie wyników analizy Boxa-Coxa zbudowano model regresji liniowej dla zmiennych przetransformowanych:

$$\ln(Y_i) = \beta_0 + \beta_1 t_i + \varepsilon_i \quad (3)$$

Powyższe równanie liniowe w skali logarytmicznej jest matematycznie równoważne **modelowi wykładniczemu** w skali oryginalnej. Po obustronnym zlogarytmowaniu ($e^{\dots}$) otrzymujemy:


$$Y_i = e^{\beta_0 + \beta_1 t_i} \cdot e^{\varepsilon_i} = \alpha \cdot e^{\beta_1 t_i} \quad (4)$$

gdzie $\alpha = e^{\beta_0}$ to stężenie początkowe, a β_1 to stała szybkości reakcji (powinna być ujemna). Taka postać modelu jest zgodna z prawem kinetyki chemicznej dla reakcji I rzędu.

Wyniki estymacji: Dokonano transformacji odwrotnej, aby obliczyć stężenia przewidywane $\hat{Y}$ i porównać je z obserwowanymi.

Tabela 12: Statystyki modelu logarytmicznego

	R-squared (log scale)	Corr (orig scale)	Lambda used
Model Log (ln Y)	0.9930	0.9946	0.0000



Rysunek 5: Dopasowanie modelu wykładniczego (po transformacji odwrotnej). Model idealnie podąża za danymi.

4.4 Model z transformacją czasu (Podpunkt f)

Alternatywnie, zamiast transformować Y , przekształcono zmienną niezależną (czas), wprowadzając nową zmienną $\tilde{t}$:


$$\tilde{t} = \frac{1}{\sqrt{t}} \quad (5)$$

Model regresji przyjmuje wtedy postać odwrotnej funkcji pierwiastkowej:

$$Y_i = \beta_0 + \beta_1 \cdot \frac{1}{\sqrt{t_i}} + \varepsilon_i \quad (6)$$

Tabela 13: Statystyki modelu z transformacją czasu (slope)

	R-squared	Corr	P-val
Model X-Trans	0.9881	0.9940	0.0000

Rysunek 6: Dopasowanie modelu z transformacją $1/\sqrt{t}$.

4.5 Podsumowanie i dyskusja wyników

Celem zadania było znalezienie modelu najlepiej opisującego spadek stężenia roztworu w czasie. Przeanalizowano trzy podejścia, których wyniki zestawiono poniżej.

Tabela 14: Porównanie jakości dopasowania modeli

Model	R-squared	Korelacja (Orig)	Uwagi
Liniowy ($Y \sim t$)	0.8116	0.9009	Nieliniowe reszty
Logarytmiczny ($\ln Y \sim t$)	0.9930	0.9946	Najlepsze dopasowanie
Transf. czasu ($Y \sim 1/\sqrt{t}$)	0.9881	0.9940	Brak uzasadnienia fiz.

Szczegółowa analiza porównawcza:

1. Model Liniowy ($Y \sim t$):

- **Ocena:** Niepoprawny.
- **Powód:** Mimo $R^2 \approx 0.81$, wykres reszt wykazuje silną strukturę (nieliniowość). Co więcej, model ten przewiduje, że po odpowiednio długim czasie stężenie spadnie poniżej zera, co jest sprzeczne z prawami fizyki.

2. Model Logarytmiczny ($\ln Y \sim t$):

- **Ocena:** Najlepszy.
- **Statystyka:** R^2 bliskie 1.0, reszty losowe, korelacja predykcji z danymi niemal idealna.
- **Fizyka/Chemia:** Model ten po przekształceniu to $Y = C \cdot e^{-kt}$. Model ten ma sensowne uzasadnienie teoretyczne – szybkość reakcji jest proporcjonalna do aktualnego stężenia.

3. Model z transformacją czasu ($Y \sim 1/\sqrt{t}$):

- **Ocena:** Akceptowalny statystycznie, ale słabszy teoretycznie.
- **Statystyka:** R^2 jest bardzo wysokie, porównywalne z modelem logarytmicznym.
- **Interpretacja:** Trudno znaleźć uzasadnienie fizykochemiczne dla zależności stężenia od odwrotności pierwiastka z czasu w prostych roztworach. Jest to model czysto empiryczny, podczas gdy model wykładniczy wynika z natury zjawiska.

Ostateczna rekomendacja: Zdecydowanie wybieramy Model Logarytmiczny. Łączy on doskonałe dopasowanie statystyczne z poprawną interpretacją fizyczną zjawiska kinetycznego.