

Sprawozdanie z Laboratorium 5

Wiktor Zoga

31 stycznia 2026

1 Zadanie 1: Regresja Liniowa na Danych Medycznych

Celem zadania była analiza zależności poziomu satysfakcji pacjenta od jego wieku, ciężkości choroby oraz poziomu niepokoju. Wykorzystano model regresji liniowej wielokrotnej.

1.1 Estymacja parametrów i testy istotności (a, c)

Poniższa tabela przedstawia oszacowane współczynniki regresji, ich błędy standardowe oraz wyniki testów t-Studenta.

Tabela 1: Estymatory, testy istotności i przedziały ufności (Zadanie 1a, 1c)

Zmienna	Współczynnik	Błąd Std	Statystyka t	p-value	95% CI Dolny	95% CI Górny
const	1.0532	0.6138	1.7160	0.0935	-0.1854	2.2919
Age	-0.0059	0.0031	-1.8973	0.0647	-0.0121	3.73e-04
Severity	0.0019	0.0058	0.3332	0.7407	-0.0097	0.0136
Anxiety	0.0301	0.0093	3.2569	0.0022	0.0115	0.0488

Wnioski: Na podstawie p-wartości można stwierdzić, które zmienne są istotne statystycznie przy poziomie istotności $\alpha = 0.05$. Przedziały ufności wskazują zakres, w którym z 95% prawdopodobieństwem znajduje się prawdziwa wartość parametru.

1.2 Dopasowanie modelu (b)

Ocenę jakości dopasowania modelu oraz wynik ogólnego testu F przedstawiono poniżej.

Tabela 2: Ocena dopasowania modelu i ogólny test F (Zadanie 1b)


R-kwadrat	Adj. R-kwadrat	Statystyka F	p-value (F)	df Model	df Reszty
0.5415	0.5088	16.5376	3.04e-07	3.0000	42.0000

Wysoka wartość statystyki F (oraz p-value < 0.05) świadczy o tym, że model jako całość jest istotny statystycznie.

1.3 Diagnostyka reszt (d)


W celu weryfikacji założeń modelu przeanalizowano rozkład reszt.

Analiza Reszt: Zależności i Wartości Odstające



Rysunek 1: Wykresy rozrzutu reszt względem wartości dopasowanych oraz zmiennych objaśniających.

Wykresy nie wykazują wyraźnych struktur, co sugeruje liniowość zależności. Aby sprawdzić normalność rozkładu reszt, sporządzono histogram oraz wykres kwantylowy (Q-Q plot).



Rysunek 2: Diagnostyka normalności reszt.

Wynik testu statystycznego Shapiro-Wilka:

Tabela 3: Test normalności reszt Shapiro-Wilka (Zadanie 1d)

Test	Statystyka W	p-value	Decyzja (alpha=0.05)
Shapiro-Wilk	0.9629	0.1481	Normality

1.4 Porównanie modeli (e)

Przeprowadzono test F w celu sprawdzenia, czy dodanie zmiennych *Severity* i *Anxiety* do modelu zawierającego tylko *Age* istotnie poprawia dopasowanie.

2 Zadanie 2: Wpływ wysokiego wymiaru danych

W zadaniu sprawdzamy, jak zachowuje się regresja, gdy mamy bardzo dużo zmiennych ($p = 950$) w stosunku do liczby obserwacji ($n = 1000$). Tylko pierwsze 5 zmiennych faktycznie wpływa na wynik ($\beta = 3$), reszta to szum.

2.1 Punkt B: Modele oparte na pierwszych k kolumnach

W tym kroku dodawaliśmy kolejne zmienne zgodnie z ich kolejnością w pliku.

Tabela 4: Wyniki regresji dla punktu b

k	SSE	MSE	AIC	p X1	p X2	FP
1	1361.0054	0.3360	310.2237	0.0000	—	0
2	1282.2922	0.8223	252.6492	0.0000	0.0000	0
5	975.3407	7.3033	-14.9684	0.0000	0.0000	0
10	971.9580	10.6861	-8.4427	0.0000	0.0000	0
50	937.8749	44.7691	35.8613	0.0000	0.0000	0
100	873.2252	109.4189	64.4382	0.0000	0.0000	6
500	489.2595	493.3845	285.1378	1.57e-09	2.94e-11	28
950	43.8282	938.8158	-1227.4775	0.2951	0.1696	18

Obserwacje:

- SSE (błąd dopasowania) zawsze spada, gdy dodajemy zmienne. Jest to jednak złudne – przy $k = 950$ błąd prawie znika (43.82), ale model przestaje widzieć istotność prawdziwych zmiennych (X_1, X_2).
- AIC poprawnie wskazuje najlepszy model dla $k = 5$ (wartość -14.96). Jednak przy $k = 950$ AIC "wariuje" i pokazuje ogromną wartość ujemną, co błędnie sugeruje idealny model.

2.2 Punkt C: Wybór zmiennych z największymi współczynnikami

Tutaj wybieraliśmy zmienne nie po kolei, ale te, które miały najwyższe wyliczone współczynniki $\hat{\beta}$ w pełnym modelu.

Tabela 5: Wyniki regresji dla punktu c

k	SSE	MSE	AIC	TP	FP
1	1395.1811	370.4290	335.0242	1	0
2	1240.2176	281.2722	219.2868	2	0
5	1238.8119	283.7671	224.1528	2	0
10	1212.9137	298.9966	213.0254	2	1
50	1075.3234	232.2150	172.6214	3	5
100	932.9998	209.8877	130.6497	4	13
500	263.8108	718.8333	-332.5232	5	332
950	43.8282	938.8158	-1227.4775	2	18

Obserwacje: Wybieranie zmiennych na podstawie tego, jak wysokie mają współczynniki, to "oszukiwanie" statystyki. Widzimy to po bardzo dużej liczbie fałszywych odkryć (FP) – np. dla $k = 500$ model uznał aż 332 nieistotnych zmiennych za ważne.

2.3 Punkt D: Wyniki z 1000 symulacji

Tabela poniżej pokazuje średnie wyniki z powtórzenia całego eksperymentu 1000 razy.

Tabela 6: Wyniki symulacji (punkt d)

k	Pow X1 (B)	Pow X2 (B)	E(FD) (B)	Pow X1 (C)	Pow X2 (C)	E(FD) (C)
1	1.0000	0.0000	0.0000	0.1070	0.0900	0.0690
2	1.0000	1.0000	0.0000	0.1570	0.1600	0.1300
5	1.0000	1.0000	0.0000	0.2800	0.2600	0.3790
10	1.0000	1.0000	0.2350	0.3590	0.3410	0.8240
50	1.0000	1.0000	2.2120	0.5690	0.5760	4.8160
100	1.0000	1.0000	4.7000	0.6760	0.6800	11.4960
500	1.0000	1.0000	24.8030	0.9100	0.9190	286.5000
950	0.4510	0.5180	48.9320	0.4510	0.5180	48.9320

Wyniki i wnioski:

- **Słaba wykrywalność w punkcie C:** Jeśli wybieramy zmienne "najsilniejsze" z danych, często pomijamy te prawdziwe. Moc dla $k = 1$ spadła z 100% (w punkcie B) do zaledwie 10% (w punkcie C).
- **Zalew fałszywych odkryć:** Punkt C generuje ogromną liczbę błędów ($E[FD]$). Szukając na siłę najlepszych zmiennych, po prostu wybieramy te, które przypadkiem zgrały się z szumem.
- **Problem $k = 950$:** Gdy zmiennych jest prawie tyle co danych, testy przestają działać. Nawet w "uczciwym" punkcie B moc wykrywania X_1 spada do ok. 45%.

2.4 Wnioski końcowe

- **Dlaczego tak się dzieje?** W zadaniu sygnał jest słaby. Wariancja jednej ważnej zmiennej to $3^2 \cdot 0.1^2 = 0.09$, a wariancja błędu to 1.0. Szum jest więc 11 razy silniejszy niż pojedyncza zmienna.
- **Selekcja zmiennych:** Scenariusz (b) jest bezpieczniejszy, bo nie manipulujemy wyborem. Scenariusz (c) pokazuje, że wybieranie zmiennych "bo mają wysokie wyniki" prowadzi do wyciągania błędnych wniosków z szumu.
- **AIC w wysokim wymiarze:** Przy dużej liczbie zmiennych ($p \approx n$) tradycyjne wskaźniki jak AIC zawodzą – promują zbyt skomplikowane modele, które po prostu "uczą się szumu" na pamięć.